DIGBA

Pipeline de Données MVP

Document de Reference Technique

Projet	DIGBA — MEST Africa EIT
Version	MVP v1.0
Date	Mars 2026
Statut	Interne Reference equipe

by Babacar Ndao ***Tech & AI LEAD***

1. Resume Executif

Ce document decrit en detail l'architecture du pipeline de donnees qui alimente le score de risque DIGBA. Il est destine a l'equipe technique et produit pour aligner la comprehension commune de chaque source de donnees, son role, son impact dans le scoring, et ses limites connues.

Argument central : pourquoi ce pipeline suffit pour le MVP

Chaque source couvre un vecteur de risque que les deux autres ne voient pas.

NDVI voit la parcelle au moment de la croissance.

La meteo voit les conditions de stockage et de transport.

RASFF valide les predictions contre l'historique de rejets reels en Europe.

Le formulaire operateur fournit le contexte que les capteurs ne peuvent pas donner.

Toutes les sources sont gratuites, accessibles aujourd'hui, et le pipeline tourne en moins de 5 secondes par lot.

1.1 Vue d'ensemble de l'architecture

Source	Nature	Frequence	Poids dans le score
Satellite NDVI	Terrain / mesure indirecte	Par scene (~5 jours)	35%
Meteo wttr.in	Temps reel	A la demande	25%
RASFF EU	Historique rejets	Statique (mis a jour manuellement)	25%
Formulaire operateur	Manuel / contexte	Par analyse de lot	15%

Note : les pondérations ci-dessus sont des hypotheses initiales fondées sur l'analyse RASFF et la litterature scientifique sur les mycotoxines. Elles seront calibrees empiriquement a partir des données collectées lors des 3 premiers pilotes exportateurs.

2. Source 1 — Satellite NDVI (Sentinel-2)

2.1 Description

Le NDVI (Normalized Difference Vegetation Index) est un indice calculé à partir de deux bandes spectrales capturées par le satellite Sentinel-2 de l'ESA. Il mesure l'état de santé de la végétation sur une parcelle agricole.

Sentinel-2 est un programme public de l'Agence Spatiale Européenne. Les données sont entièrement gratuites et accessibles via AWS S3 sans authentification. La résolution est de 10 mètres par pixel, ce qui permet d'analyser des parcelles agricoles individuelles.

2.2 Comment on l'obtient

Etape 1 — Identifier la tuile Sentinel-2 de la zone d'interet :

- Kaolack / Thiès / Dakar : tuile 28PBV
- Saint-Louis : tuile 28QCE
- Casamance (Ziguinchor) : tuile 28PCQ
- Outil de reference : mgrs-mapper.com

Etape 2 — Telecharger les bandes necessaires depuis AWS S3 :

```
BASE="https://sentinel-s2-l2a.s3.amazonaws.com/tiles/28/P/BV/2024/1/12/0/R10m"wget
"$BASE/B04.jp2" -O B4.jp2   # Bande rouge (RED)wget "$BASE/B08.jp2" -O B8.jp2   #
Infrarouge (NIR)
```

Etape 3 — Calculer le NDVI avec Python/rasterio :

```
import numpy as npimport rasteriowith rasterio.open("B4.jp2") as src:    RED =
src.read(1).astype(float)with rasterio.open("B8.jp2") as src:    NIR =
src.read(1).astype(float)np.seterr(divide="ignore", invalid="ignore")NDVI = (NIR -
RED) / (NIR + RED)NDVI = np.clip(NDVI, -1, 1)
```

2.3 Interpretation des valeurs NDVI

Valeur NDVI	Interpretation	Signification terrain	Risque DIGBA
< 0	Eau / sol mineral	Ocean, zone urbaine, sol nu total	Neutre (hors zone agricole)
0 a 0.2	Vegetation tres sparse	Sol stresse, jachère, debut de saison sèche	Eleve — stress hydrique
0.2 a 0.4	Vegetation moderee	Plante en croissance, conditions acceptables	Modere
0.4 a 0.6	Bonne vegetation	Croissance saine, defenses naturelles actives	Faible

Valeur NDVI	Interpretation	Signification terrain	Risque DIGBA
> 0.6	Vegetation tres dense	Conditions optimales — rare en zone sèche	Tres faible

2.4 Impact dans le score DIGBA

Le NDVI contribue a hauteur de 35% au score de risque final. Son role principal est de detecter le stress vegetatif de la parcelle au moment de la recolte.

Mecanisme de correlation avec les dangers :

Danger	Lien avec NDVI	Logique scientifique
Aflatoxine B1	NDVI < 0.2 => risque +40%	Plante stressée => defenses réduites => Aspergillus colonise
Stress hydrique	NDVI < 0 en zone agricole => anomalie	Secheresse = mycotoxines pendant la croissance
Pesticides excessifs	NDVI anormal hors saison	Usage intensif = residus potentiels sur les cultures
Qualite generale	Correlation NDVI / KOR anacarde	NDVI > 0.4 => meilleur taux de rendement noyau

2.5 Defis et limites connues

Limite 1 — Le NDVI ne voit pas l'interieur du grain

Le satellite mesure l'etat de la canopee, pas le contenu du grain. Un NDVI correct ne garantit pas qu'il n'y a pas de contamination au stockage.

=> Complement obligatoire : donnees meteo post-recolte (humidite, temperature) + test terrain AFB1.

Limite 2 — Resolution spatiale et coordonnees GPS

La resolution est de 10m/pixel. Sans les coordonnees GPS exactes de la parcelle, on analyse la zone generale de la ville, pas la parcelle precise.

=> Solution MVP : utiliser les coordonnees GPS de la region de production (Kaolack, Thiès...) comme approximation.

=> Solution V2 : integration GPS terrain dans le formulaire operateur.

Limite 3 — Couverture nuageuse

Une scene Sentinel-2 couverte de nuages donne des valeurs NDVI faussees. Il faut selectionner la scene la plus recente sans nuages, pas la plus recente en date.

=> Gestion dans le pipeline : verifier le metadata de couverture nuageuse avant de telecharger (champ cloudCoverPercentage < 20%).

3. Source 2 — Meteo (wttr.in)

3.1 Description

wttr.in est une API météo gratuite, sans authentification, développée en open source. Elle agrège des données de plusieurs services météorologiques mondiaux et les expose en JSON via une simple requête HTTP.

Pour DIGBA, la météo sert à mesurer les conditions de stockage et de transport du lot — deux facteurs critiques qui déterminent si une contamination va se développer après la récolte.

3.2 Comment on l'obtient

```
import requestsdef get_weather(city: str) -> dict:    r =
requests.get(f"https://wttr.in/{city}?format=j1", timeout=10)    data = r.json()
current = data["current_condition"][0]    return {        "humidity":
int(current["humidity"]),        "temp_c":      int(current["temp_C"]),
"precip_mm":   float(current["precipMM"]),        "wind_kmph":
int(current["windspeedKmph"]),        "uv_index":    int(current["uvIndex"])    }#
Exempleweather = get_weather("Kaolack")
```

3.3 Variables meteorologiques et leur role

Variable	Seuil critique	Danger associe	Mecanisme
Humidite > 70%	> 70%	Aflatoxine / moisissures	Aspergillus flavus prolifere en conditions humides
Temperature	25-35°C	Toutes mycotoxines	Zone de croissance optimale des champignons pathogenes
Precipitations recentes	> 5mm/24h	Humidite residuelle grain	Pluie avant recolte = grain humide = risque stockage
Index UV	UV > 8	Stress vegetal indirect	UV extreme => stress plante => resistance reduite
Vent > 30km/h	> 30 km/h	Contamination croisee	Spores transportees entre parcelles voisines

3.4 Impact dans le score DIGBA

La météo contribue à hauteur de 25% du score. Son role est double : predictor de risque pendant la croissance (conditions passees) et indicateur de risque au moment du stockage (conditions presentes).

Condition meteo	Ajustement score	Produits concernes
Humidite > 70% + Temp 25-35°C	+20 points au sous-score	Tous produits (arachide, maïs prioritaires)
Precipitations > 5mm dans les 48h	+15 points au sous-score	Cereales, sesame, arachide
Humidite < 50% + Temp < 25°C	-10 points au sous-score	Anacarde, mangue (conditions favorables)
Saison seche confirmee	-5 points (bonus parcelle saine)	Tous produits

3.5 Defis et limites connues

Limite 1 — Meteo ville vs meteo parcelle

wttr.in retourne la meteo de la ville de reference, pas de la parcelle agricole exacte. Kaolack (ville) peut avoir des conditions differentes d'une ferme a 30km.

=> Impact MVP : acceptable pour une premiere approximation.

=> Solution V2 : utiliser les coordonnees GPS de la parcelle + Open-Meteo ou NASA POWER API.

Limite 2 — Absence d'historique meteo

wttr.in ne fournit que les conditions actuelles et les 3 prochains jours. Or, l'aflatoxine se developpe pendant les 3-4 semaines precedant la recolte — on a besoin de l'historique.

=> Solution pour la V1.1 : integrer Open-Meteo (historique 90 jours, gratuit) pour recuperer les conditions pendant la periode de croissance.

Limite 3 — Disponibilite du service

wttr.in est un service communautaire sans SLA garanti. En cas d'indisponibilite, le pipeline doit avoir un fallback.

=> Fallback recommande : Open-Meteo API (https://open-meteo.com) — egalement gratuit, historique disponible, plus stable.

4. Source 3 — RASFF (Alertes EU)

4.1 Description

Le RASFF (Rapid Alert System for Food and Feed) est la base de données officielle de la Commission Européenne qui répertorie toutes les alertes de sécurité alimentaire détectées aux frontières ou sur les marchés européens.

Pour DIGBA, le dataset RASFF constitue le socle de connaissance historique : il documente précisément quels produits sénégalais ont été rejetés, pour quels dangers, par quels pays et à quelle fréquence.

4.2 Analyse du dataset RASFF Senegal (36 entrees)

Le dataset actuel couvre les alertes impliquant des produits d'origine sénégalaise sur les marchés européens.

Repartition par categorie de produit :

Categorie	Nb alertes	% du total	Classification predominante
Fruits et legumes	11	30.6%	Alerte + Rejet frontiere
Poissons et produits de la peche	7	19.4%	Information pour attention
Crustaces et produits	4	11.1%	Information + Alerte
Cereales et produits de boulangerie	4	11.1%	Alerte (mycotoxines)
Noix, graines et produits	3	8.3%	Alerte (aflatoxines)
Graisses et huiles	2	5.6%	Information
Autres (epices, supplements, etc.)	5	13.9%	Variable

Top 4 dangers identifies (sur l'ensemble des 36 alertes) :

Danger	Cas	Produits concernes	Reglementation EU
Chlorpyrifos (pesticide interdit)	8	Fruits, legumes, haricot vert	Interdiction totale depuis 2020
Aflatoxine B1 (mycotoxine)	7	Arachides, noix, cereales	Limite : 5 ppb (UE)
Cadmium (metal lourd)	4	Mangue, anacarde	Limite : 0.05 mg/kg (UE)
Mercure (metal lourd)	4	Poissons, crustaces	Limite : 0.5 mg/kg (UE)

Pays notifiants (top detecteurs de produits senegalais) :

Pays	Alertes	% du total	Implication pour DIGBA
Belgique	10	27.8%	Hub de transit majeur — controles stricts
Pays-Bas	7	19.4%	Port de Rotterdam — point d'entree EU
Espagne	7	19.4%	Marche direct fruits/legumes frais
Allemagne	4	11.1%	Marche de transformation
France	3	8.3%	Produits tropicaux et mangues

4.3 Comment RASFF alimente le score

Le dataset RASFF est charge au demarrage du pipeline comme une table de reference. Il est interroge de 4 façons différentes :

- Lookup produit x danger : si la combinaison (produit = mangue) + (danger = cadmium) existe dans RASFF avec une frequence > 2, un bonus de risque est applique automatiquement.
- Score de frequence : le nombre d'alertes par type de produit determine le score de base de ce produit avant meme de regarder le NDVI ou la meteo.
- Historique fournisseur : si un nom de fournisseur ou une region apparait dans les alertes passees, le score de confiance est reduit de 10 a 20 points.
- Marche cible : si l'exportateur vise la Belgique, les Pays-Bas ou l'Espagne (67% des alertes), le seuil de validation est abaisse — le score doit etre plus bas pour considerer le lot acceptable.

4.4 Defis et limites connues

Limite 1 — Volume de donnees insuffisant

36 entrees pour le Senegal, c'est insuffisant pour entrainer un modele ML robuste de façon autonome.

=> Strategie : utiliser RASFF comme prior (connaissance a priori), pas comme dataset d'entrainement.

=> Enrichissement V2 : combiner avec les donnees collectees aupres des 3 exportateurs pilotes.

Limite 2 — RASFF est reactif, pas predictif

RASFF documente ce qui s'est passe, pas ce qui va se passer. Un nouveau danger emergent n'apparait pas dans RASFF avant qu'un rejet ait eu lieu.

=> C'est precisement la valeur ajoutee de DIGBA : combiner RASFF (historique) avec NDVI + meteo (signal avance) pour predire avant le rejet.

Limite 3 — Maintenance du dataset

RASFF est mis a jour en continu par la Commission Europeenne. Notre dataset doit etre actualise regulierement.

=> Processus recommande : verification mensuelle sur le portail RASFF Window (window.rasff.eu) et mise a jour de la table de reference.

5. Source 4 — Formulaire operateur

5.1 Description

Le formulaire operateur est la saisie manuelle réalisée par l'exportateur ou l'agent DIGBA sur le terrain. Il fournit le contexte business que les capteurs et bases de données ne peuvent pas donner : quel produit, quelle région, quel fournisseur, pour quel marché.

C'est le point d'entrée de tout le pipeline. Sans ces informations, DIGBA ne sait pas quelle tuile satellite télécharger, quelle météo interroger, ni quelles règles RASFF appliquer.

5.2 Champs du formulaire et role dans le pipeline

Champ	Exemple	Role dans le pipeline	Impact sur le score
Region d'origine	Senegal, Kaolack	Selectionne la tuile Sentinel-2 + meteo locale	Indirect — conditionne tous les autres scores
Type de produit	Arachide	Active les regles de risque specifiques produit	Direct — score de base RASFF par produit
Periode de recolte	Novembre 2025	Determine la saison + selectionne la bonne scene NDVI	Direct — saison seche = risque aflatoxine +
Profil fournisseur	Mamadou Ndao Trading	Croisement avec RASFF + historique pilotes	Direct — fournisseur inconnu = -10 points confiance
Marche cible	Union Europeenne / France	Selectionne le referentiel reglementaire applicable	Direct — seuils MRL differents selon le marche
Volume du lot (kg)	5000 kg	Parametrage de l'analyse de risque economique	Indirect — aide au calcul ROI du test terrain

5.3 Defis et limites connues

Limite 1 — Dependance humaine et risque d'erreur de saisie

Si l'operateur saisit une mauvaise region ou un mauvais produit, tout le pipeline est fausse. Un lot d'arachides saisi comme 'sesame' aura un profil de risque incorrect.

=> Mitigation : validation des inputs avec listes deroulantes pre-definies pour les champs critiques (region, produit, marche cible).

=> Validation croisee : verifier que la region saisie correspond a une zone de production connue pour le produit selectionne.

Limite 2 — Connectivite terrain

Les zones de production (Kaolack, Ziguinchor, Saint-Louis) ont une couverture internet variable.

=> Architecture requise : Progressive Web App (PWA) avec mode offline. Les analyses sont mises en file d'attente localement et synchronisees quand le reseau revient.

=> Priorite MVP : s'assurer que le formulaire fonctionne sans connexion et envoie les donnees de façon asynchrone.

6. Feature Engineering et Calcul du Score

6.1 Feature engineering

Avant d'entrer dans le moteur de scoring, les donnees brutes de chaque source sont transformees en features normalisees comparables. Cette etape est critique : sans normalisation, un NDVI de 0.3 et une humidite de 70 ne peuvent pas etre additionnes directement.

Feature brute	Transformation	Feature normalisee	Plage de sortie
NDVI (float)	Inversion + normalisation lineaire	ndvi_risk_score	0 (bon) a 100 (mauvais)
Humidite (%)	Seuil : 50% => 0 pts, 90% => 100 pts	humidity_risk_score	0 a 100
Temperature (°C)	Courbe en cloche : 28°C = max risque	temp_risk_score	0 a 100
Freq. RASFF produit	Normalisation sur max historique	rasff_freq_score	0 a 100
Statut fournisseur	Encodage categoriel (connu/inconnu/alerte)	supplier_trust_score	0 a 100
Saison recolte	Encodage binaire (seche/pluies)	season_risk_flag	0 ou 1

6.2 Formule de calcul du score final

Le score final DIGBA est une combinaison lineaire ponderee des sous-scores de chaque source. La formule MVP est la suivante :

```
Score_DIGBA = (0.35 x ndvi_risk_score)             + (0.25 x
meteo_risk_score)             + (0.25 x rasff_freq_score)             +
(0.15 x operator_context_score)Meteo_risk_score = 0.6 x humidity_risk_score
+ 0.4 x temp_risk_score
```

6.3 Interpretation du score

Score	Niveau de risque	Decision recommandee	Actions requises
0 — 35%	Faible	Achat recommande	Verifications standard + certificat phytosanitaire
35 — 65%	Modere	Achat conditionnel	Test terrain obligatoire avant engagement financier

Score	Niveau de risque	Decision recommandee	Actions requises
> 65%	Eleve	Rejeter ou renégocier	Negocier le prix en integrant le cout du risque ou refuser

6.4 Regles d'override (score automatique maximum)

Certains dangers declenchent un score de 100% (rejet automatique) independamment des autres features, car leur presence signifie un rejet europeen garanti :

- Detection de chlorpyrifos => Score = 100% (substance interdite en EU depuis 2020)
- Aflatoxine B1 > 5 ppb confirme par test terrain => Score = 100%
- Fournisseur blackliste (present dans RASFF avec rejet < 12 mois) => Score = 95%
- Region sous alerte phytosanitaire active (DPVC Senegal) => Score = 90%

7. Pourquoi ce pipeline suffit pour le MVP

7.1 Les 5 arguments cles

1 **Zero cout de donnees**
Sentinel-2 (ESA), wttr.in, RASFF (Commission EU) sont tous publics et gratuits. Le pipeline peut tourner aujourd'hui sans negociation de contrat ni budget data.

2 **Complementarite totale des sources**
Aucune source ne fait doublon. NDVI voit la parcelle. La meteo voit le stockage. RASFF valide contre l'historique EU. Le formulaire donne le contexte. Quatre vecteurs de risque distincts.

3 **Execution en moins de 5 secondes**
Le pipeline complet — download NDVI reduit + appel meteo + lookup RASFF — s'execute en moins de 5 secondes. Viable pour une decision terrain avant achat.

4 **Base validee par des rejets reels**
Le dataset RASFF represente 36 rejets documentés de produits sénégalais en Europe. Ce ne sont pas des hypothèses — ce sont des faits verifies par les autorites europeennes. Le pipeline est ancre dans la realite des marchés.

5 **Evolutivite integree**
L'architecture est modulaire. Chaque source peut etre remplacee ou enrichie independamment. NDVI => images drone en V2. wttr.in => Open-Meteo avec historique. RASFF => donnees pilotes terrain.

7.2 Hypotheses assumees et plan de validation

Ce que nous assumons et comment nous le validerons

Les pondérations (0.35 / 0.25 / 0.25 / 0.15) sont des priors bases sur la litterature scientifique et l'analyse RASFF.

Elles ne sont pas arbitraires — mais elles doivent etre calibrées empiriquement sur des donnees reelles.

Plan de validation :

=> Recruter 3 exportateurs pilotes et tracker leurs lots sur une saison complete

=> Pour chaque lot : noter le score DIGBA, le resultat du test terrain AFB1, et le verdict a l'export

=> Apres 50 lots documentes : recalibrer les poids avec une regression logistique simple

=> Le MVP sert precisement a COLLECTER ces donnees de calibration

8. Roadmap Technique

8.1 MVP (0-3 mois) — Ce qui est en cours

Composant	Description	Statut
Download NDVI	Sentinel-2 via AWS S3, scale 1/4, rasterio	Termine
Calcul NDVI	Pipeline Python, export GeoTIFF + PNG	Termine
Meteo wttr.in	Appel API, parsing JSON, extraction 5 variables	A faire
RASFF lookup	Table SQLite locale, requetes produit x danger	A faire
Feature engineering	Normalisation + ponderation des sous-scores	A faire
UI DIGBA (formulaire)	Interface web React/HTML, demo interactive	En cours
Integration pipeline complet	Connexion des 4 sources en un seul appel API	A faire

8.2 V1.1 (3-6 mois) — Enrichissement data

- Remplacement wttr.in par Open-Meteo avec historique 90 jours
- Ajout coordonnees GPS parcelle dans le formulaire operateur
- Integration du kit de test terrain AFB1 (saisie resultat physique dans l'app)
- Dashboard exportateur avec historique des lots analyses
- Debut collecte donnees pilotes (3 exportateurs partenaires)

8.3 V2 (6-12 mois) — Intelligence et scalabilite

- Modele ML supervise entraine sur donnees pilotes (XGBoost ou Random Forest)
- Calibration empirique des pondérations sur 50+ lots documentes
- Expansion geographique : integration tuiles Sentinel-2 pour Cote d'Ivoire, Ghana
- API DIGBA publique pour integration dans les outils des exportateurs
- Score de confiance fournisseur base sur l'historique terrain cumule

9. Glossaire

Terme	Definition
AFB1	Aflatoxine B1 — mycotoxine cancérigene produite par le champignon Aspergillus flavus. Limite EU : 5 ppb dans les denrees alimentaires.
NDVI	Normalized Difference Vegetation Index. Indice de sante vegetale calcule depuis les bandes spectrales satellite. Plage : -1 a +1.
NIR	Near-Infrared. Bande infrarouge proche — bande B8 de Sentinel-2. Reflechie fortement par la vegetation saine.
RASFF	Rapid Alert System for Food and Feed. Systeme d'alerte rapide europeen pour la securite alimentaire.
ppb	Parts per billion (parties par milliard). Unite de mesure des contaminants traces dans les aliments.
MRL	Maximum Residue Level. Teneur maximale en residus de pesticides autorisee par la reglementation europeenne.
KOR	Kernel Out-turn Rate. Taux de rendement en noix d'anacarde. Mesure la qualite de l'anacarde brut.
DXA	Decitwips par inch. Unite de mesure des dimensions dans les documents OOXML (.docx).
Tuile Sentinel-2	Zone geographique de reference du systeme Sentinel-2. La tuile 28PBV couvre la region de Dakar/Kaolack.
Prior (ML)	Connaissance a priori incorporee dans un modele avant de voir des donnees reelles. Dans DIGBA : les pondérations initiales basees sur RASFF.
Feature engineering	Transformation des donnees brutes en variables numeriques comparables utilisables par un modele de scoring ou ML.
DPVC	Direction de la Protection des Vegetaux et du Conditionnement — autorite phytosanitaire du Senegal.

Fin du document

DIGBA — MVP Data Pipeline Reference | MEST Africa | Mars 2026

Babacar Ndao **Tech & AI LEAD**